# Αλγόριθμοι Αναζήτησης

#### Δημήτρης Φωτάκης

Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Εθνικό Μετσόβιο Πολυτεχνείο



### Γραμμική Αναζήτηση

Μοναδικός τρόπος όταν:

Αλγόριθμοι & Πολυπλοκότητα (Χειμώνας 2018)

- είτε όχι ταξινομημένος πίνακας,
- είτε μόνο σειριακή προσπέλαση (π.χ. αρχεία).

```
int linearSearch(int A[], int n, int x) {
   for (int i = 0; i < n; i++)
      if (x == A[i]) return(i);
   return(-1); }
```

Χρόνος χ.π. / αποτυχημένης αναζήτησης: Θ(*n*) (βέλτιστος). Χρόνος καλύτερης περίπτωσης: Θ(1).

## Γραμμική Αναζήτηση (μ.π.)

- $\Box$  Πιθανότητα αναζήτησης στοιχείου k = 1 / n
  - 'Ολα τα στοιχεία αναζητούνται ισοπίθανα!

$$\square$$
 Χρόνος μ.π.  $=\sum_{i=k}^{n} \mathbb{P}[k] \cdot k = \frac{n(n+1)}{2n} = \frac{n+1}{2}$ 

### Γραμμική Αναζήτηση (μ.π.)

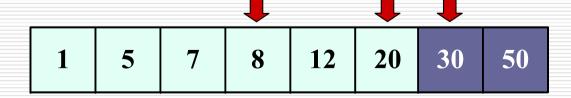
- 'Όχι ισοπίθανη αναζήτηση:
  - Μπροστά στοιχεία με μεγαλύτερη συχνότητα αναζήτησης.
- Δεν γνωρίζουμε συχνότητες:
  - Σταδιακή αναδιοργάνωση : μπροστά στοιχεία που ζητούνται.
  - Move-to-Front : χρόνος  $\leq 2 \times \beta$ έλτιστος, λίστα.
  - Move-Forward : πίνακας, όχι βελτίωση αν μόνο δύο στοιχεία.
- □ Self-adjusting DS: «προσαρμόζεται» ώστε να είναι ταχύτερη στο μέλλον (βλ. splay trees).

Μέσος #συγκρίσεων = 3.8

### Δυαδική Αναζήτηση

- Ταξινόμηση και τυχαία προσπέλαση.
- $\square$  Χρόνος  $O(\log n)$  (βέλτιστος ως προς χ.π.).

Αναζήτηση 30:



### Ορθότητα

- $\square$  Av A[ mid ] > k, k μπορεί να βρίσκεται μόνο αριστερά.
- $\square$  Av A[ mid ] < k, k μπορεί να βρίσκεται μόνο δεξιά.
- Σε κάθε επανάληψη, πλήθος υποψήφιων στοιχείων μειώνεται (περίπου) στο μισό :

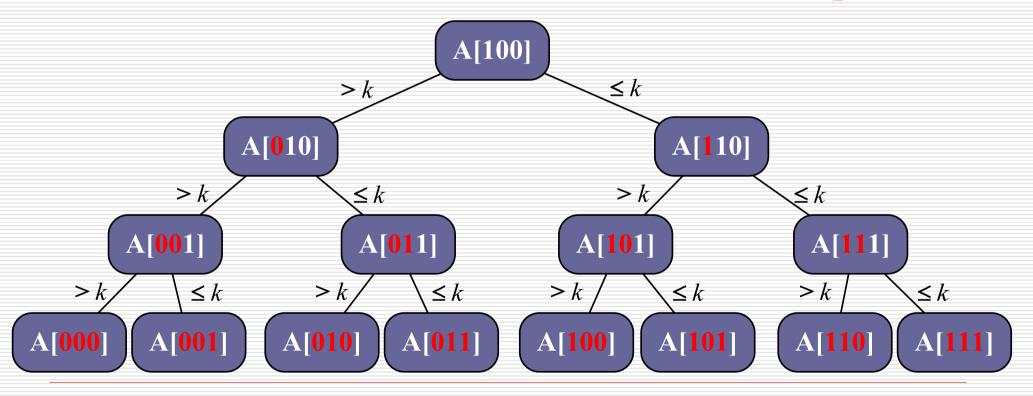
$$n, \frac{n}{2}, \frac{n}{4}, \cdots, \frac{n}{2^{\ell}}, \cdots, 1 \Rightarrow \ell \approx \log_2 n$$

Χρόνος O(log n): βέλτιστος (χειρότερη περίπτωση).



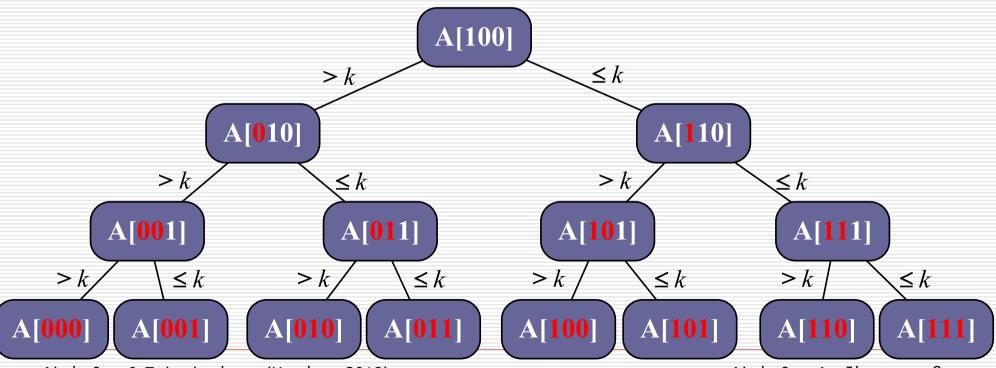
#### Χρόνος Εκτέλεσης

- Δυαδική αναπαράσταση θέσεων: κάθε σύγκριση προσδιορίζει ένα bit της θέσης του στοιχείου!
- Δυαδικό δέντρο συγκρίσεων έχει n φύλλα και log<sub>2</sub> n ύψος.



### Χρόνος Εκτέλεσης

- Για κάθε αλγόριθμο, χωρίς άλλη πληροφορία (π.χ. κατανομή στοιχείων), μία σύγκριση προσδιορίζει ένα bit θέσης στοιχείου.
- Αν δεν γνωρίζουμε κατανομή στοιχείων, κάθε αλγόριθμος
   αναζήτησης χρειάζεται χρόνο Ω(log n) στη χειρότερη περίπτωση.



- Συνήθως έχουμε κάποια πληροφορία σχετικά με την κατανομή των στοιχείων (π.χ. όταν ψάχνουμε τον τηλεφωνικό κατάλογο δεν ανοίγουμε στη μέση).
- Παρεμβολή αξιοποιεί την πληροφορία κατανομής.
   Ταχύτερη (στη μέση περ.) από δυαδική.
  - Αν ξέρουμε κατανομή, μια σύγκριση μπορεί να δίνει περισσότερο από ένα bit πληροφορίας για θέση στοιχείου.
  - Αναμενόμενη θέση *k* στο A[ *low ... up* ]:

```
pos = low + (k - A[low]) / μέση αύξηση
/ ανά θέση
```

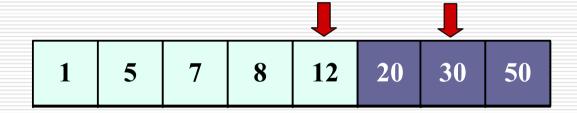
Κατά τα άλλα ίδια με δυαδική.

- Εκδοχή για ομοιόμορφη κατανομή σε διάστημα.
  - Προσαρμόζεται σε οποιαδήποτε άλλη κατανομή.

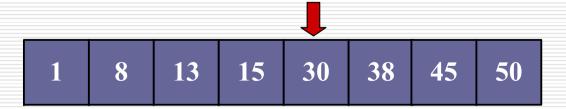
```
pos = low + (k - A[low]) 	imes rac{up - low}{A[up] - A[low]}
int interpolationSearch(int A[], int n, int k) {
    int low = 0, up = n-1, pos;
    while (low <= up) {</pre>
     if ((k < A[low]) | | (k > A[up])) return(-1);
     pos = low + (int) ((double) (up - low))*
        (((double) (k - A[low])) / ((double) (A[up] - A[low])));
        if (A[pos] == k) return(pos);
        else if (A[pos] > k) up = pos - 1;
                                    low = pos + 1;
             else
    return(-1);
```

$$pos = low + (k - A[low]) imes rac{up - low}{A[up] - A[low]}$$

Αναζήτηση 30:



Αναζήτηση 30:



- Χρόνος μέσης περίπτωσης : O(loglog n)
  - Αναζήτηση σε 1 τρισεκατ. στοιχεία με 6 συγκρίσεις!
- Χρόνος χειρότερης περίπτωσης : O(n)
- Χρόνος χειρότερης περίπτωσης βελτιώνεται με Δυαδική Αναζήτηση με Παρεμβολή.
- Πρώτη επανάληψη βρίσκει περιοχή με ακρίβεια. Επόμενες προσπελάσεις στην ίδια περιοχή.
  - Καλή αξιοποίηση της cache memory.